书生浦语大模型开源开放体系

- 开源之路

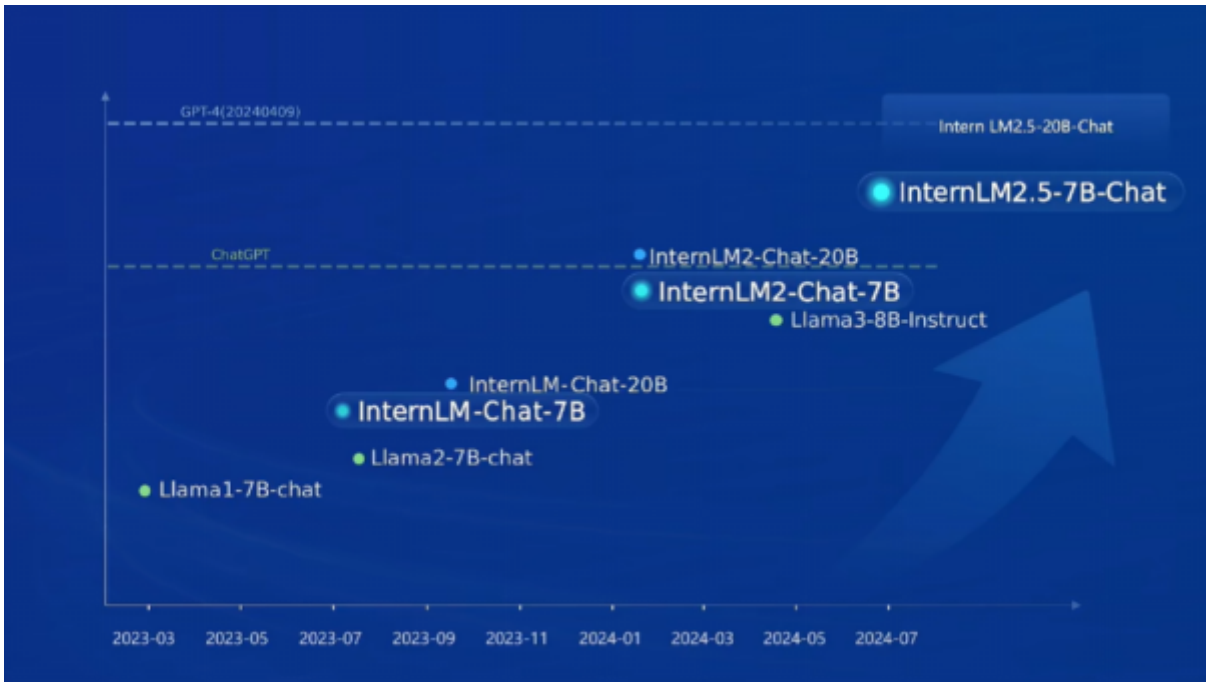

  - 2023.7.6 InternLM-7B 开源率先免费商用，发布全聊条开源工具体系
  - 2023.9.20 20B开源，工具链全线升级
  - 2024.1.17 InternLM2开源
  - 2024.7.4 2.5开源
  - 书生浦语大模型2.5

    - 性能提升
        - 2.5相对于2性能提升20%
        - 上下文tokens限制提升至100万
    - 功能增强
        - 大规模上下文处理
        - 自主规划和搜索复杂任务能力

- 核心技术
    - 模型能力飞轮（当前模型-->更好模型）自身迭代
        - 当前模型进行数据过滤，智能评估得到预训练数据
        - 当前模型通过指令生成，辅助标注对齐数据
    - 高质量合成数据
        - 基于规则的数据构造
        - 基于模型的数据扩充
        - 基于用户反馈的数据生成
- 全链条开源

- 数据：
  - 书生·万卷首个精细处理的开源多模态语料库数据

- 数据处理
  - 数据提取：MinerU，一站式开源高质量数据提取工具，支持多格式(PDF/网页/电子书)，智能萃取，生成高质量预训练/微调语料。
    - 复杂版面/公式精准识别
    - 性能超过商业软件
    - Http://github.com/opendatalab/MinerU
  - 数据标注
    - Label LLM:专业致力于 LLM 对话标注，通过灵活多变的工具配置与多种数据模态的广泛兼容，为大模型量身打造高质量的标注数据。
      - 支持指令采集、偏好收集、对话评估……
      - 多人协作、任务管理、源码开放可魔改
      - Http://github.com/opendatalab/LabelLLM

    - Label U：一款轻量级开源标注工具，自由组合多样工具，无缝兼容多格式数据，同时支持载入预标注，加速数据标注效率。
        - 支持图片、视频、音频多种数据标注0
        - 小巧灵活，AI标注导入二次人工精修
        - Http://github.com/opendatalab/labelU
- 预训练：InternEvo，性能超过国际主流训练框架DeepSpeed

- 微调：XTuner，多种微调和偏好对齐算法，支持千亿参数+百万上下文

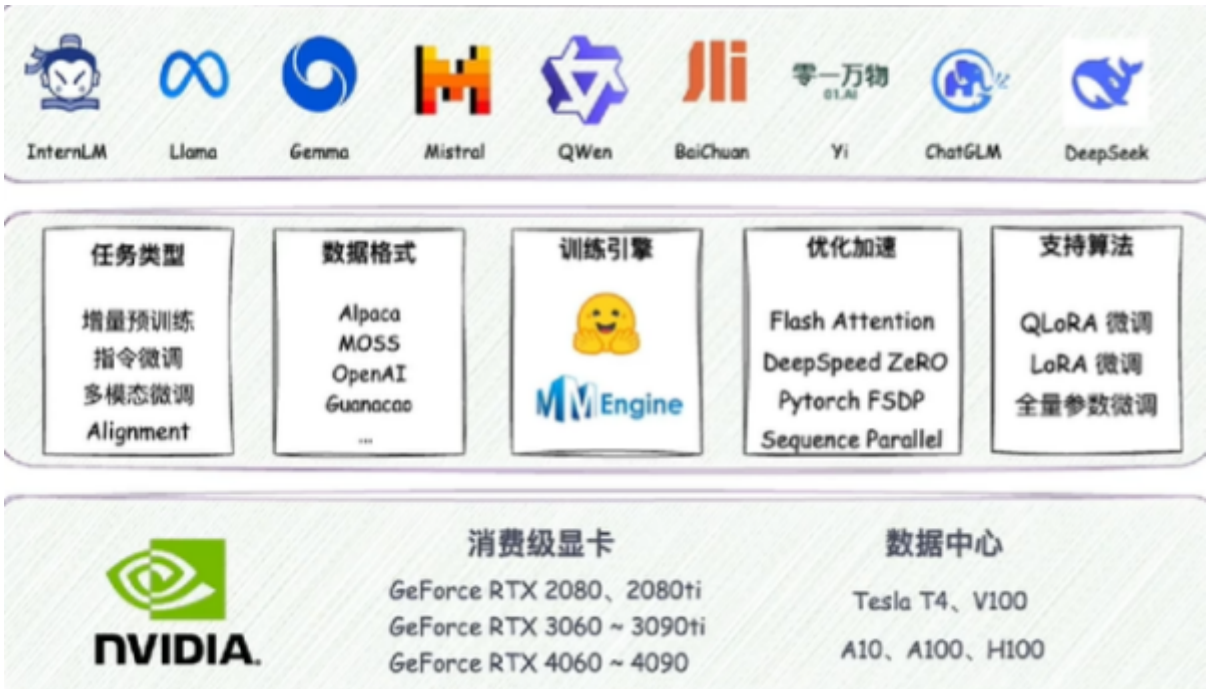

- 适配多种生态：多种微调算法多种微调 & 偏好对齐算法，覆盖各类应用场景。
- 适配多种开源生态：支持加载 HuggingFace、ModelScope 模型或数据集。
- 自动优化加速：开发者无需关注复杂的显存优化与计算加速细节支持千亿参数 +百万上下文训练。

- 部署：LMDeploy，性能超过国际主流推理框架 vlm
  - 高效的推理引擎：
    - TurboMind 推理引擎：LMDeploy 使用 TurboMind 作为高性能的推理引擎，能够显著提升模型的推理速度。
    - PyTorch 推理后端：支持使用 PyTorch 作为推理后端，确保与现有生态系统的兼容性。
  - 可靠的量化技术：
    - Weight-only 量化：通过只对权重进行量化，减少模型的存储和计算需求，同时保持较高的推理精度。
    - K/V Cache 量化：对 K/V Cache 进行量化，进一步优化内存使用和推理速度。
  - 多样的接口支持：
    - Python 推理接口：提供 Python 接口，方便开发者在 Python 应用中调用模型。
    - RESTful 接口：支持 RESTful API，使 Web 应用和其他系统可以通过 HTTP 请求调用模型。
    - gRPC 接口：支持 gRPC 协议，提供高性能的 RPC 服务，适用于微服务架构。
  - 卓越的兼容性：
    - 类 OpenAI 服务：提供类似于 OpenAI 的服务接口，方便开发者迁移和集成。
    - Gradio：支持 Gradio，一个用于快速构建和共享机器学习应用的工具。
    - Triton 推理服务：支持 NVIDIA Triton 推理服务器，提供高性能的多模型推理能力。
- 评测：OpenCompass，社区最全面的开源评测体系
- 应用：大模型具有局限性

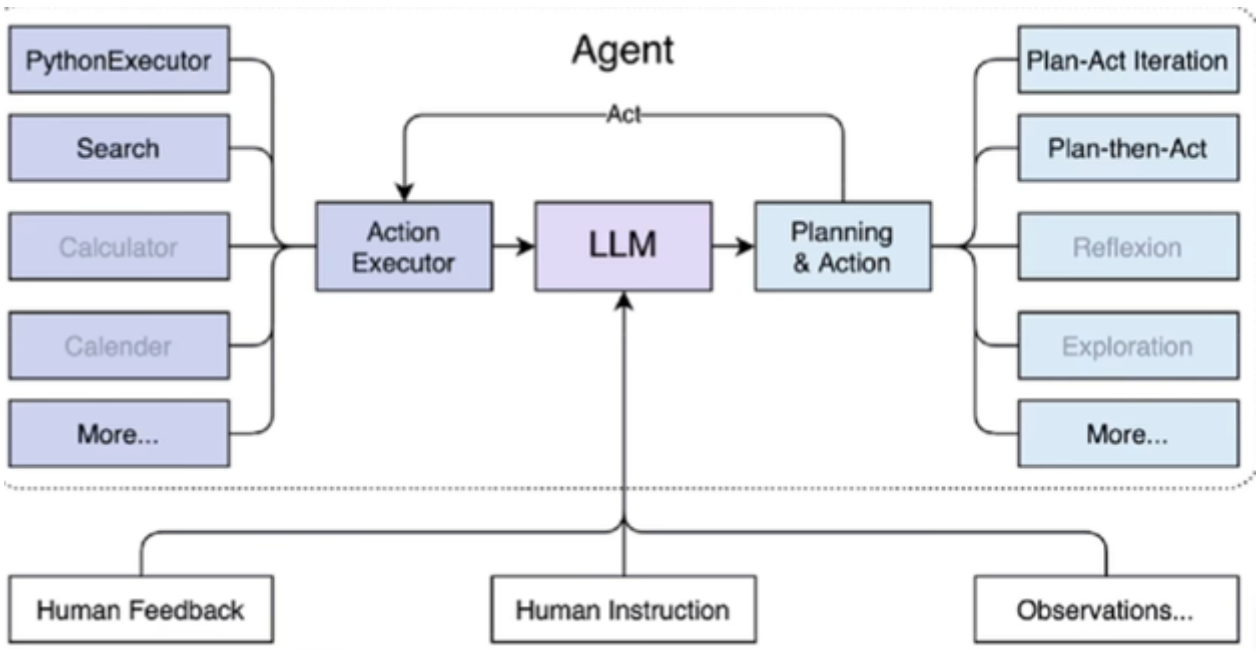

- MindSearch 思索式开源搜索应用
- Lagent 首个支持代码解释器的智能体框架，轻量级

    - 支持多种类型智能体能力
        - ReAct
        - ReWoo
        - AutoGPT
    - 支持多种大语言模型：GPT-3.5/4，IntrenLM，HuggingFace Transformers，Llama
    - 支持丰富的工具
        - AI工具：文生图、文生语音、图片描述
        - 能力拓展：搜素、计算机、代码解释器
        - Rapid API：出行API、财经API、体育资讯API
- MinerU 高效文档解析工具
- HuixiangDou 基于专业知识库的群聊助手，企业级知识库构建工具，群聊场景 LLM 知识助手，为即时通讯(如微信、飞书)群聊场景设计。
    - 利用检索增强生成(RAG)，非参数记忆，利用外部知识库提供实时更新的信息。
    - 利用知识图谱KG，结构化知识库匹配意图行为可解释。
    - 场景特点
        - 无关问题不吭声
        - 明确回答直接回复
        - 不违背核心价值观